Labolatorium 6

April 16, 2026

Jakub Orchowski, s223281

1 CEL CWICZENIA

Kreslenie krzywych na obrazie zdyskretyzowanym oraz aproksymacja zbiorow punktow metoda najmniejszych kwadratow.

[1]:
```
import numpy as np
import matplotlib.pyplot as plt
from PIL import Image
%matplotlib inline
```

2 Zadania

2.1 Zadanie 1.

Na obrazie o rozdzielczosci 640x480 rysuje krzywa $y = A\sqrt{x}$ dla kilku dodatnich wartosci parametru A. Konstrukcja wykorzystuje operacje calkowitoliczbowe i laczy kolejne probki odcinkami Bresenhama, dzieki czemu zachowuje ciaglosc takze dla stromego poczatku krzywej.

[2]:
```
IMAGE_WIDTH = 640
IMAGE_HEIGHT = 480
A_VALUES = [8, 18, 28]


def draw_bresenham_line(image: np.ndarray, start: tuple[int, int], end:␣
↪tuple[int, int], value: int = 255) -> None:
    """Rysuje odcinek w przestrzeni pikselowej wyłącznie operacjami␣
↪całkowitoliczbowymi."""
    x0, y0 = start
    x1, y1 = end
    dx = abs(x1 - x0)
    sx = 1 if x0 < x1 else -1
    dy = -abs(y1 - y0)
    sy = 1 if y0 < y1 else -1
    error = dx + dy

    while True:
```

```
        if 0 <= x0 < image.shape[1] and 0 <= y0 < image.shape[0]:
            image[y0, x0] = value
        if x0 == x1 and y0 == y1:
            break
        doubled_error = 2 * error
        if doubled_error >= dy:
            error += dy
            x0 += sx
        if doubled_error <= dx:
            error += dx
            y0 += sy


def math_to_image_point(x: int, y: int, height: int) -> tuple[int, int]:
    """Zamienia wspolrzedne matematyczne na pikselowe przy odwroconej osi Y."""
    return x, height - 1 - y


def rasterize_sqrt_curve(width: int, height: int, a: int, value: int = 255) ->␣
 ↪tuple[np.ndarray, np.ndarray]:
    """Rasteryzuje krzywa y = a * sqrt(x) bez uzycia liczb zmiennoprzecinkowych.
 ↪"""
    if a <= 0:
        raise ValueError('Parametr a musi byc dodatni.')

    image = np.zeros((height, width), dtype=np.uint8)
    sampled_points: list[tuple[int, int]] = []
    a_squared = a * a
    y = 0
    previous_pixel: tuple[int, int] | None = None

    for x in range(width):
        target = 4 * a_squared * x
        while (2 * y + 1) * (2 * y + 1) <= target:
            y += 1

        sampled_points.append((x, y))
        pixel = math_to_image_point(x, y, height)

        if previous_pixel is None:
            if 0 <= pixel[0] < width and 0 <= pixel[1] < height:
                image[pixel[1], pixel[0]] = value
        else:
            draw_bresenham_line(image, previous_pixel, pixel, value)

        previous_pixel = pixel
        if y >= height:
```

```
            break

    return image, np.array(sampled_points, dtype=np.int64)


fig, axes = plt.subplots(1, len(A_VALUES), figsize=(18, 5))
curve_summaries = []

for ax, a in zip(axes, A_VALUES):
    image, sampled_points = rasterize_sqrt_curve(IMAGE_WIDTH, IMAGE_HEIGHT, a)
    visible_points = sampled_points[sampled_points[:, 1] < IMAGE_HEIGHT]
    last_visible_x, last_visible_y = visible_points[-1]
    ax.imshow(image, cmap='gray', vmin=0, vmax=255)
    ax.set_title(f'Krzywa dla A = {a}')
    ax.axis('off')
    curve_summaries.append((a, int(last_visible_x), int(last_visible_y), int(np.
 ↪count_nonzero(image))))

plt.tight_layout()
plt.show()

for a, last_visible_x, last_visible_y, pixel_count in curve_summaries:
    print(
        f'A = {a}: ostatni widoczny punkt ma wspolrzedne (x, y) =␣
 ↪({last_visible_x}, {last_visible_y}), '
        f'a liczba zapalonych pikseli wynosi {pixel_count}.'
    )
```

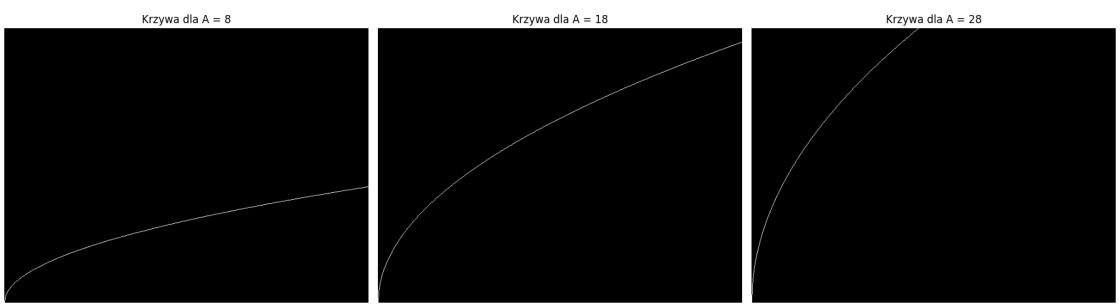


```
A = 8: ostatni widoczny punkt ma wspolrzedne (x, y) = (639, 202), a liczba
zapalonych pikseli wynosi 656.
A = 18: ostatni widoczny punkt ma wspolrzedne (x, y) = (639, 455), a liczba
zapalonych pikseli wynosi 721.
A = 28: ostatni widoczny punkt ma wspolrzedne (x, y) = (293, 479), a liczba
zapalonych pikseli wynosi 490.
```

2.1.1 Wnioski

Calkowitoliczbowe kryterium doboru kolejnej probki pozwala narysowac krzywa bez uzycia pierwiastka i bez rachunku zmiennoprzecinkowego. Laczenie kolejnych punktow odcinkami Bresenhama usuwa przerwy przy stromym poczatku, a dla duzych wartosci A algorytm poprawnie obcina fragment wychodzacy poza obraz.

2.2 Zadanie 2.

Dla kilku uporzadkowanych zbiorow punktow wyznaczam aproksymacje najmniejszych kwadratow modelem $y = a + b \sin x + cx^2$. Poniewaz wspolczynniki wystepuja liniowo, problem sprowadza sie do rozwiazania ukladu dla macierzy projektujacej z baza $[1, \sin x, x^2]$.

[3]:
```
def build_design_matrix(x: np.ndarray, basis_functions: list) -> np.ndarray:
    """Buduje macierz projektujaca dla zadanego zestawu funkcji bazowych."""
    return np.column_stack([basis_function(x) for basis_function in␣
 ↪basis_functions]).astype(np.float64)


def fit_linear_model(x: np.ndarray, y: np.ndarray, basis_functions: list) ->␣
 ↪tuple[np.ndarray, np.ndarray, float]:
    """Wyznacza parametry modelu liniowego oraz blad sredniokwadratowy."""
    design_matrix = build_design_matrix(x, basis_functions)
    coefficients, _, _, _ = np.linalg.lstsq(design_matrix, y, rcond=None)
    fitted_values = design_matrix @ coefficients
    mse = float(np.mean((y - fitted_values) ** 2))
    return coefficients, fitted_values, mse


def evaluate_linear_model(x: np.ndarray, coefficients: np.ndarray,␣
 ↪basis_functions: list) -> np.ndarray:
    """Oblicza wartosci modelu dla nowego wektora argumentow."""
    return build_design_matrix(x, basis_functions) @ coefficients


def plot_approximation(ax, x: np.ndarray, y: np.ndarray, coefficients: np.
 ↪ndarray, basis_functions: list, title: str) -> None:
    """Rysuje punkty i dopasowana krzywa dla wybranego modelu."""
    dense_x = np.linspace(x.min(), x.max(), 400)
    dense_y = evaluate_linear_model(dense_x, coefficients, basis_functions)
    ax.scatter(x, y, color='black', label='Punkty')
    ax.plot(dense_x, dense_y, color='tab:red', label='Aproksymacja')
    ax.set_title(title)
    ax.grid(alpha=0.25)
    ax.legend()
```

```python
synthetic_x = np.array([0.0, 4.0, 8.0, 12.0, 16.0, 20.0, 24.0], dtype=np.
 ↪float64)
synthetic_y = 3.0 + 4.2 * np.sin(synthetic_x) + 0.025 * synthetic_x ** 2 + np.
 ↪array([0.0, 0.8, -0.5, 1.2, -1.0, 0.6, -0.4])

datasets_approximation = [
    ('Zestaw 1', np.array([(1, 2), (3, 8), (7, 13), (12, 12), (56, 2)],␣
 ↪dtype=np.float64)),
    ('Zestaw 2', np.array([(1, 2), (13, 18), (27, 23), (32, 12), (56, 42)],␣
 ↪dtype=np.float64)),
    ('Zestaw 3', np.column_stack([synthetic_x, synthetic_y])),
]

basis_task2 = [
    lambda values: np.ones_like(values, dtype=np.float64),
    np.sin,
    lambda values: values ** 2,
]

fig, axes = plt.subplots(1, len(datasets_approximation), figsize=(18, 5))
task2_results = []

for ax, (name, points) in zip(axes, datasets_approximation):
    x = points[:, 0]
    y = points[:, 1]
    coefficients, fitted_values, mse = fit_linear_model(x, y, basis_task2)
    plot_approximation(ax, x, y, coefficients, basis_task2, name)
    task2_results.append((name, coefficients, mse))

plt.tight_layout()
plt.show()

for name, coefficients, mse in task2_results:
    print(
        f'{name}: a = {coefficients[0]:.4f}, b = {coefficients[1]:.4f}, '
        f'c = {coefficients[2]:.6f}, MSE = {mse:.4f}'
    )
```

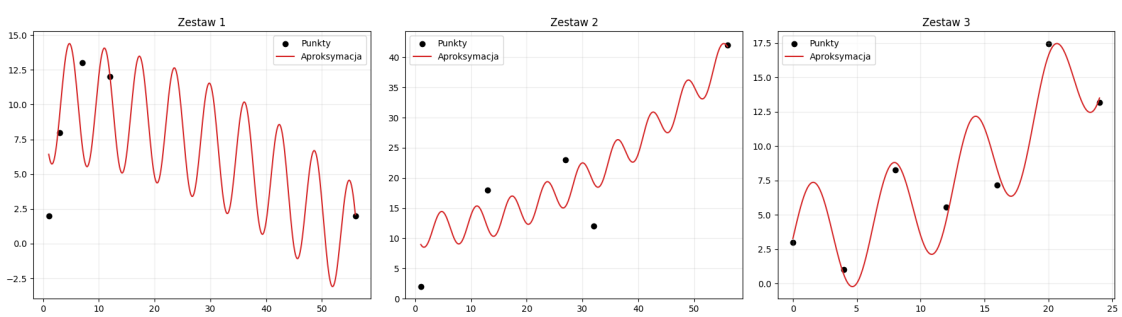

```
Zestaw 1: a = 10.0981, b = -4.3655, c = -0.003280, MSE = 11.3681
Zestaw 2: a = 11.3672, b = -2.8696, c = 0.009214, MSE = 39.7571
Zestaw 3: a = 3.2803, b = 4.0260, c = 0.024063, MSE = 0.4960
```

2.2.1 Wnioski

Model z baza $[1, \sin x, x^2]$ daje rozwiazanie przez jedno wywolanie metody najmniejszych kwadratow, bo wspolczynniki sa liniowe mimo nieliniowych funkcji argumentu. Dopasowana krzywa dobrze wygładza niewielkie zbiory punktow, ale przy ekstrapolacji poza zakres danych coraz silniej dominuje skladnik kwadratowy.

2.3 Zadanie 3.

Przy tych samych zbiorach punktow dopasowuje model $y = a(\sin x)^2 + b\cos x + c\sqrt[3]{x}$. Porownuje przebiegi dopasowanych krzywych i bledy sredniokwadratowe z poprzednim zadaniem.

[4]:
```
basis_task3 = [
    lambda values: np.sin(values) ** 2,
    np.cos,
    np.cbrt,
]

fig, axes = plt.subplots(1, len(datasets_approximation), figsize=(18, 5))
task3_results = []

for ax, (name, points) in zip(axes, datasets_approximation):
    x = points[:, 0]
    y = points[:, 1]
    coefficients, fitted_values, mse = fit_linear_model(x, y, basis_task3)
    plot_approximation(ax, x, y, coefficients, basis_task3, name)
    task3_results.append((name, coefficients, mse))

plt.tight_layout()
plt.show()

for name, coefficients, mse in task3_results:
    print(
        f'{name}: a = {coefficients[0]:.4f}, b = {coefficients[1]:.4f}, '
        f'c = {coefficients[2]:.4f}, MSE = {mse:.4f}'
    )
```

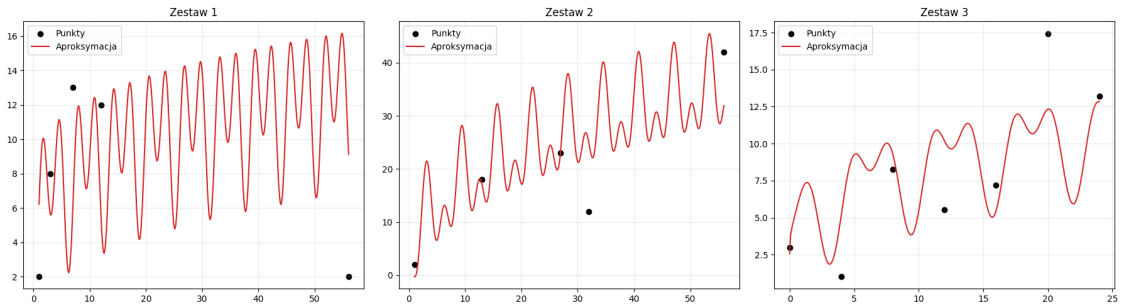


```
Zestaw 1: a = 7.0747, b = -2.1276, c = 2.3550, MSE = 32.8345
Zestaw 2: a = -10.4336, b = -6.1444, c = 10.4549, MSE = 54.8085
Zestaw 3: a = 3.6229, b = 2.5818, c = 3.0384, MSE = 9.9081
```

2.3.1 Wnioski

Drugi model korzysta z innego zestawu funkcji bazowych, dlatego mimo tej samej metody obliczen moze prowadzic do wyraznie innego ksztaltu krzywej i innego bledu dopasowania. Skladnik z pierwiastkiem stopnia trzeciego rośnie wolniej od skladnika kwadratowego, wiec lepiej opisuje przypadki, w ktorych trend nie powinien zbyt szybko uciekać dla duzych x.

2.4 Zadanie 4.

Losuje po 30 wartosci x_i z przedzialu $[-10, 10]$, generuje punkty wedlug zaleznosci $y_i = -0.5x_i^2 + 2x_i + rand(i)$ z szumem z przedzialu $[-3, 3]$ i dopasowuje parabole $y = ax^2 + bx + c$. Powtarzam doswiadczenie wielokrotnie, a nastepnie porownuje otrzymane wspolczynniki i ich wartosci srednie.

[5]:
```python
def generate_random_parabola_sample(rng: np.random.Generator, sample_size: int␣
↪= 30) -> tuple[np.ndarray, np.ndarray]:
    """Generuje losowy zbior punktow zgodnie z trescia zadania."""
    x = np.sort(rng.uniform(-10.0, 10.0, size=sample_size))
    noise = rng.uniform(-3.0, 3.0, size=sample_size)
    y = -0.5 * x ** 2 + 2.0 * x + noise
    return x, y


basis_parabola = [
    lambda values: values ** 2,
    lambda values: values,
    lambda values: np.ones_like(values, dtype=np.float64),
]

rng = np.random.default_rng(2026)
trial_count = 25
selected_trials = {0, 12, 24}
trial_coefficients = []
```

```
trial_mse = []
selected_samples = []

for trial_index in range(trial_count):
    x, y = generate_random_parabola_sample(rng)
    coefficients, fitted_values, mse = fit_linear_model(x, y, basis_parabola)
    trial_coefficients.append(coefficients)
    trial_mse.append(mse)
    if trial_index in selected_trials:
        selected_samples.append((trial_index + 1, x, y, coefficients, mse))

trial_coefficients = np.vstack(trial_coefficients)
coefficient_means = trial_coefficients.mean(axis=0)
coefficient_stds = trial_coefficients.std(axis=0)
true_coefficients = np.array([-0.5, 2.0, 0.0])

fig, axes = plt.subplots(1, len(selected_samples), figsize=(18, 5))
for ax, (trial_number, x, y, coefficients, mse) in zip(axes, selected_samples):
    dense_x = np.linspace(-10.0, 10.0, 400)
    ax.scatter(x, y, color='black', label='Punkty')
    ax.plot(dense_x, evaluate_linear_model(dense_x, coefficients,␣
 ↪basis_parabola), color='tab:blue', label='Aproksymacja')
    ax.plot(dense_x, evaluate_linear_model(dense_x, true_coefficients,␣
 ↪basis_parabola), linestyle='--', color='tab:orange', label='Model zrodlowy')
    ax.set_title(f'Proba {trial_number}, MSE = {mse:.2f}')
    ax.grid(alpha=0.25)
    ax.legend()

plt.tight_layout()
plt.show()

trial_numbers = np.arange(1, trial_count + 1)
parameter_names = ['a', 'b', 'c']

fig, axes = plt.subplots(1, 3, figsize=(18, 4))
for ax, parameter_name, parameter_values, true_value in zip(axes,␣
 ↪parameter_names, trial_coefficients.T, true_coefficients):
    ax.plot(trial_numbers, parameter_values, marker='o', markersize=3)
    ax.axhline(true_value, color='tab:red', linestyle='--')
    ax.set_title(f'Wspolczynnik {parameter_name}')
    ax.set_xlabel('Numer proby')
    ax.grid(alpha=0.25)

plt.tight_layout()
plt.show()

difference = coefficient_means - true_coefficients
```

```
print(
    f'Srednie wspolczynniki: a = {coefficient_means[0]:.4f}, b =␣
 ↪{coefficient_means[1]:.4f}, '
    f'c = {coefficient_means[2]:.4f}'
)
print(
    f'Odchylenia standardowe: a = {coefficient_stds[0]:.4f}, b =␣
 ↪{coefficient_stds[1]:.4f}, '
    f'c = {coefficient_stds[2]:.4f}'
)
print(f'Sredni blad MSE: {np.mean(trial_mse):.4f}')
print(
    f'Srednie odchylenie od modelu zrodlowego: a = {difference[0]:+.4f}, '
    f'b = {difference[1]:+.4f}, c = {difference[2]:+.4f}'
)
```

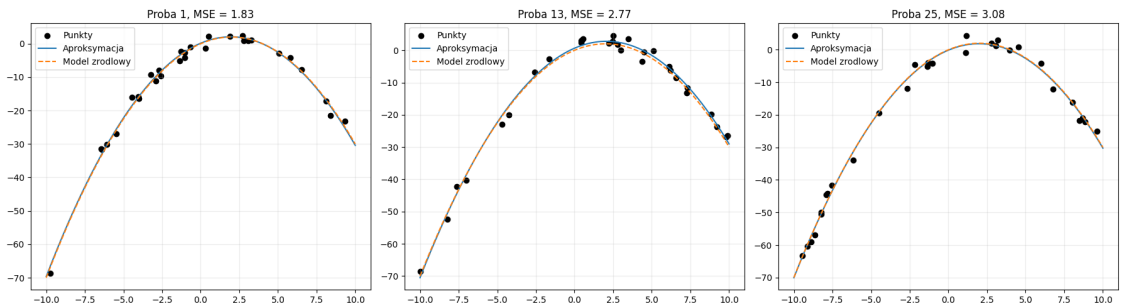

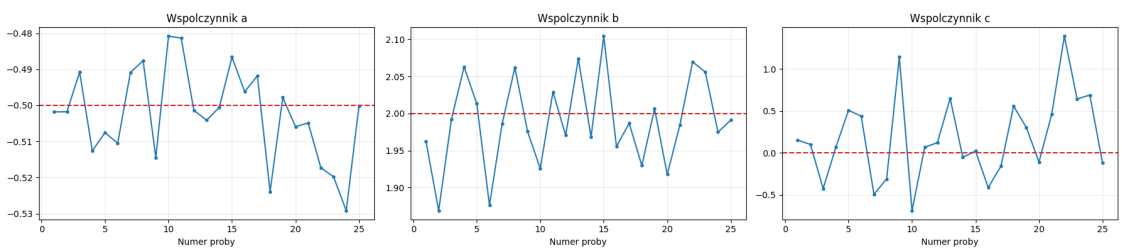


```
Srednie wspolczynniki: a = -0.5024, b = 1.9898, c = 0.1820
Odchylenia standardowe: a = 0.0125, b = 0.0592, c = 0.4918
Sredni blad MSE: 2.6655
Srednie odchylenie od modelu zrodlowego: a = -0.0024, b = -0.0102, c = +0.1820
```

2.4.1 Wnioski

Dla pojedynczej proby wspolczynniki paraboli zmieniaja sie przez losowy skladnik zaklocajacy, ale srednie z wielu uruchomien pozostaja blisko modelu zrodlowego. Zwieszanie liczby prob stabilizuje ocene parametrow, bo dodatni i ujemny szum stopniowo sie znosi i coraz slabiej przesuwa wartosci

srednie.