

GRAFIKA KOMPUTEROWA I KOMUNIKACJA Z KOMPUTEREM

Wykład 11

Andrzej Śluzek

pokój: 3/64

email: andrzej_sluzek@sggw.edu.pl



Tematyka wykładów i zajęć laboratoryjnych

(oficjalny sylabus, kolejność i tematyka może być nieco inna)

1. Wstęp. Urządzenia graficzne wejścia-wyjścia.
2. Podstawowe pojęcia i definicje dotyczące obrazów cyfrowych (w technice rastrowej i wektorowej) oraz modeli kolorów.
3. Punktowe, lokalne i globalne metody przekształcania obrazów.
4. Transformacje geometryczne obiektów graficznych i wypełnianie figur.
5. Eliminacja elementów zasłoniętych, metody kreślenia krzywych.
6. Modele oświetlenia i cieniowania.
7. Przekształcenia morfologiczne i ich zastosowania.
8. Transformaty obrazów i sygnałów dźwiękowych (FFT, **Hough, Radon**).
- Wybrane metody filtracji danych jedno- i dwuwymiarowych.**
9. Wybrane modele interakcji człowiek-komputer. Zasady projektowania i analizy interfejsów komputerowych.
10. Interfejsy dla osób niepełnosprawnych. Interakcja człowiek-komputer dla komputerów przyszłości.

Transformacje Hough'a i Radona

Wstęp

Matematycznie, *transformata Hough'a* i *transformata Radona* są ze sobą „spokrewnione” (*transformata Radona* jest uogólnieniem jednej z *transformat Hough'a*). Są one jednak używane są do zupełnie innych celów.

Transformata Hough'a służy do „wykrywania” w obrazach linii o określonym kształcie (np. linii prostych lub okręgów) a tym samym używana jest do tworzenia „poprawionych” wersji obrazów, w których te linie oryginalnie mogły być nie w pełni widoczne lub zniekształcone.

Natomiast *transformata Radona* jest przede wszystkim jednym z fundamentalnych narzędzi *tomografii komputerowej*, gdzie służy do rekonstrukcji przekrojów obiektów (np. ciała ludzkiego).



Transformata Hough'a

Transformata Hough'a w praktyce stosowana jest wyłącznie do obrazów konturowych i jej zadaniem jest aproksymowanie w możliwie najlepszy sposób zbiorów punktów konturowych liniami z danej rodziny (tzn. wykrycie takich linii i znalezienie optymalnych parametrów ich równań).

Mówiąc ogólnie, transformata Hough'a przekształca jeden (konturowy) pixel obrazu w $(N-1)$ -wymiarową powierzchnię w N -wymiarowej przestrzeni parametrycznej (gdzie N jest liczbą parametrów opisujących daną rodzinę linii).

Na przykład, linie proste mają równanie postaci:

$$y = mx + b$$

tzn. $N = 2$ (parametry m i b).


Transformata Hough'a

Jeśli dany jest pixel o współrzędnych (x_0, y_0) , każda linia prosta przechodząca przez ten pixel musi spełniać równość:

$$y_0 = mx_0 + b$$

W przestrzeni parametrów $M \times B$ uzyskujemy więc równanie prostej:

$$b = -x_0 m + y_0$$




Transformata Hough'a

Natomiast zbiór pixeli ułożonych wzdłuż linii o równaniu


$$y = mx + b$$

generuje w przestrzeni parametrów pęk linii prostych, które przecinają się w punkcie o współrzędnych (m, b) .



Transformata Hough'a

Jeżeli pixele jedynie w przybliżeniu leżą wzdłuż linii prostej, linie odpowiadające tym pixelom przecinają się nie w jednym punkcie, a w zbiorze wielu punktów skupionych wokół punktu (m, b) reprezentującego hipotetyczną linię, wzdłuż której w przybliżeniu ułożone są te pixele.



przestrzeń parametryczna

Transformata Hough'a





W praktyce, zarówno przestrzeń obrazu $X \times Y$, jak i przestrzeń parametrów $M \times B$ jest zdyskretyzowana

W przestrzeni $X \times Y$ są to pixele, a w przestrzeni $M \times B$ „komórki” reprezentujące wszystkie wartości parametrów (m, b) , które są zaokrąglone do wartości w środku danej „komórki”.

Liczbę par linii przecinających się wewnątrz danej komórki w przestrzeni $M \times B$ można w przybliżeniu aproksymować liczbą linii przecinających tę komórkę (następny slajd).

Potencjalne istnienie linii prostej w obrazie konturowym wykrywa się zatem znajdując „komórki” w przestrzeni parametrów, które są przecinane przez największą liczbę linii prostych.

Transformata Hough'a



Liczby nie reprezentują
pokazanego zestawu pixeli.


Transformata Hough'a

Problem: przestrzeń parametrów $M \times B$ jest nieograniczona (m może przyjmować wielkie wartości nawet w obrazach o ograniczonych rozmiarach).


Korzystniej jest więc używać alternatywnego równania prostej:

$$x \cos \theta + y \sin \theta = \rho$$


Wówczas każdy pixel (x_0, y_0) generuje w przestrzeni parametrów sinusoidę o równaniu $\rho = x_0 \cos \theta + y_0 \sin \theta$, a sinusoidy współliniowych pixeli przecinają w jednym punkcie przestrzeni parametrów.



Transformata Hough'a




pixele



wyniki przecięć („głosowania”)


Ponieważ zakresy zarówno kąta θ jak i promienia ρ są skończone (przy skończonej rozdzielczości obrazu) więc można oba wymiary zdyskretyzować siatką prostokątną.

Transformata Hough'a




W przypadku istnienia linii, w przestrzeni Hough'a pojawiają się wyraźne lokalne maksima.

Transformata Hough'a




piksele




wyniki przecięć

Nawet w przypadku braku linii, mogą mimo wszystko pojawiać się przypadkowe (niezbyt wybitne) lokalne maksima w przestrzeni Hough'a.


Transformata Hough'a



obraz



detekcja konturów



wyniki przecięć

Transformata Hough'a

Podsumowanie dla linii prostych

- Możliwość użycia parametrów m, b (problemy z potencjalnie nieskończoną siatką dyskretyzacji).
- Zalecane używanie parametrów ρ, θ (skończona siatka dyskretyzacji).
- Inne istotne zagadnienia
 - Rozmiar komórek w siatce dyskretyzacji parametrów.
 - Uśrednianie zawartości komórek.
 - Jakie lokalne maksima są wystarczająco maksymalne ☺.
 - Jak znajdować odcinki? Linie proste rzadko rozciągają się od krawędzi do krawędzi obrazu. Może się nawet zdarzyć, że to samo równanie prostej opisuje dwa (lub więcej) odcinki leżące w różnych częściach obrazu.

Transformata Hough'a


Detekcja innych linii w obrazach konturowych (praktycznym ograniczeniem jest jedynie liczba parametrów w równaniu linii, bo to determinuje wymiarowość przestrzeni Hough'a).

➤ Okręgi o stałym promieniu r_0

- Równanie okręgu $(x-a)^2 + (y-b)^2 = r_0^2$
- Przestrzeń Hough'a jest 2-wymiarowa $A \times B$.
- Pixel (x_0, y_0) generuje równanie $(x_0-a)^2 + (y_0-b)^2 = r_0^2$, a więc w przestrzeni Hough'a jest to też okrąg!
- Siatka dyskretyzacji jest skończona.



➤ Okręgi o dowolnym promieniu r

- Równanie okręgu $(x-a)^2 + (y-b)^2 = r^2$
- Przestrzeń Hough'a jest 3-wymiarowa $A \times B \times R$
- Pixel (x_0, y_0) generuje równanie $(x_0-a)^2 + (y_0-b)^2 = r^2$, a więc w przestrzeni Hough'a jest to równanie *powierzchni stożkowej*.
- Siatka dyskretyzacji jest skończona (ale 3-wymiarowa).



Transformata Hough'a

Przykład zastosowania kołowej transformaty Hough'a (w kontekście niestandardowych metod komunikacji z komputerem).




Transformata Hough'a $\Rightarrow$ transformata Radona

Nieco inna interpretacja transformaty Hough'a (do wykrywania linii prostych):

$$x \cos \theta + y \sin \theta = \rho \quad \Rightarrow \quad \begin{cases} x(t) = \rho \cos \theta + t \sin \theta \\ y(t) = \rho \sin \theta - t \cos \theta \end{cases} \quad -\infty < t < +\infty$$

równanie parametryczne



Dla każdej linii, odpowiadającej pewnym wartościom ρ i θ , „sumujemy” liczbę punktów konturowych leżących wzdłuż tej linii (w praktyce zawartych w wąskiej „rurce”, której szerokość zdeterminowana jest przez dyskretyzację parametru ρ w równaniu linii prostej) $x \cos \theta + y \sin \theta = \rho$.

Transformata Hough'a $\Rightarrow$ transformata Radona

Wówczas, zakładając, że $c(x,y)$ oznacza obraz konturowy z punktami konturowymi o wartości 1 transformatę Hough'a można formalnie zapisać (teoretycznie całkowanie, a w praktyce sumowanie) jako:

$$HT(\rho, \theta) = \int_{-\infty}^{+\infty} c(\rho \cos \theta + t \sin \theta, \rho \sin \theta - t \cos \theta) dt$$
$$\begin{cases} x(t) = \rho \cos \theta + t \sin \theta \\ y(t) = \rho \sin \theta - t \cos \theta \end{cases}$$


Jeżeli jednak zamiast obrazu konturowego użyjemy dowolnego obrazu $i(x,y)$, to ten sam wzór (z taką samą interpretacją, tzn. „sumujemy” obraz wzdłuż odpowiednich linii) definiuje *transformatę Radona*.




$$RT(\rho, \theta) = \int_{-\infty}^{+\infty} i(\rho \cos \theta + t \sin \theta, \rho \sin \theta - t \cos \theta) dt$$

Transformata Radona

Przykład:



obraz



transformata Radona

Transformata Radona


Tak więc wartość *transformaty Radona* dla wybranych (θ, ρ) oznacza po prostu zsumowanie punktów obrazu („prześwietlenie”) wzdłuż linii o orientacji θ i o odległości ρ od środka układu współrzędnych. Tak właśnie (w przybliżeniu) działa tomografia komputerowa, gdzie obracamy głowicę prześwietlając pacjenta wiązką równoległych linii (promieni) z różnych kierunków.

Ponieważ *transformata Radona* jest odwracalna oznacza to, że z takich „prześwietleń” uzyskanych pod różnymi kątami możemy odtworzyć (używając *odwrotnej transformaty Radona*) treść obrazu, czyli np. wewnętrzny przekrój ciała pacjenta.



Krótkookresowa transformata Fouriera

W przypadku długich sygnałów, globalne charakterystyki częstotliwościowe (transformata Fouriera) zazwyczaj nie opisują w użyteczny sposób treści takich sekwencji. Różne częstotliwości mogą występować w różnych fragmentach sygnałów/obrazów, a transformata Fouriera informuje nas jedynie o tym, że dana częstotliwość występuje w analizowanym sygnale z określoną amplitudą i fazą.




W takich sytuacjach korzystne jest użycie tzw. **krótkookresowej transformaty Fouriera** (ang. *STFT*, *short-term Fourier transform*).

Jest ona szczególnie przydatna przy analizie i przetwarzaniu sygnałów akustycznych (np. w głosowej komunikacji między człowiekiem i komputerem).

Krótkookresowa transformata Fouriera

Przykładowe dane akustyczne



Aby uzyskać bardziej precyzyjną interpretację takich danych, należy wiedzieć kiedy (tzn. położenie we współrzędnych czasowych) poszczególne częstotliwości pojawiają się w tym sygnale.

W tym celu wykorzystujemy *krótkookresową transformatę Fouriera*.

Krótkookresowa transformata Fouriera

Definicje transformaty *STFT* dla danych ciągłych $x(t)$ i zdyskretyzowanych $x[n]$:

$$\mathcal{FT}_s[x(t)] = X(\omega, \tau) = \int_{-\infty}^{+\infty} x(t)w(t - \tau)e^{-j\omega t} dt$$

gdzie $w(t)$ jest funkcją okna.



$$\mathcal{DTFT}_s\{x[n]\} = X(\omega, N) = \sum_{n=-\infty}^{+\infty} x[n]w[n - N]e^{-j\omega n}$$

gdzie $w[n]$ jest funkcją okna.

Przesuwająca się *funkcja okna* $w(t - \tau)$ lub $w[n - N]$ „wybiera” fragment danych w zależności od aktualnego położenie okna.

Tak więc *STFT* jest funkcją dwóch argumentów: *częstotliwości* oraz *położenia okna*, tzn. określa ona jakie częstotliwości (i z jakimi amplitudami/fazami) występują we fragmencie zdefiniowanym przez dane położenie okna.


Krótkookresowa transformata Fouriera




Krótkookresowa transformata Fouriera

Wykres pokazujący zmiany STFT (tzn. zmiany amplitudy) w czasie nazywamy *periodogramem*.

Przykładowe dane




i ich *periodogram*.



Krótkookresowa transformata Fouriera

Z kolei *spektrogram* jest po prostu kwadratem *periodogramu*, tyle tylko, że zwykle reprezentowanym poziomami jasności). Jest to jedna z ważnych metod reprezentacji danych akustycznych na podstawie ich STFT.

Spektrogramy są szczególnie ważne na najniższych poziomach algorytmów analizy i syntezy dźwięku (np. rozpoznawanie mowy, konwersja *text-to-speech*, itd.).



Krótkookresowa transformata Fouriera


Intuicyjnie, funkcja okna powinna mieć kształt prostokątny. Niestety, taki kształt okna powoduje niepożądany efekt, tzw. *spectral leakage* (przeciek widma ☺ ?) .

Nieformalnie można to wyjaśnić w następujący sposób:


Sygnał $x[n]$ „obcięty” przez funkcję okna gwałtownie zaczyna się i kończy na obu końcach okna. Żeby „wygenerować” takie gwałtowne skoki, potrzebne są wysokie częstotliwości, które pojawiają się jako dodatkowe („przeciekające”) składowe o wysokich częstotliwościach w STFT danego fragmentu sygnału.

Krótkookresowa transformata Fouriera


Aby zredukować *spectral leakage*, stosuje się funkcje okna o innych niż prostokątnych kształtach. Typowe przykłady to okna Hamminga, okna gaussowskie, okna Bartletta (trójkątne), itd.



okno Hamminga




okno gaussowskie



okno trójkątne

Krótkookresowa transformata Fouriera

Przykłady okien o szerokości 32 próbek (sygnały cyfrowe)



Gdy używamy takich funkcji okna, oryginalne dane mnożone są przez liczby stopniowo zmniejszające się w miarę zbliżania się do skraju okna, tzn. dany fragment jest zniekształcony, ale obliczona w ten sposób STFT precyzyjniej pokazuje „bardziej prawdziwe” częstotliwości występujące w danych fragmencie, bo nie ma konieczności generowania gwałtownych „skoków” na skraju okna.

Krótkookresowa transformata Fouriera

Wzory cyfrowych realizacji okien nieprostokątnych (dla okien o szerokości N próbek, tzn. $n = \{0, \dots, N-1\}$).

prostokątne $w_R[n] = 1$


Hamming $w_{Hm}[n] = \alpha - \beta \cos\left(\frac{2\pi n}{N-1}\right), \quad \text{np. } 0.54 - 0.46 \cos\left(\frac{2\pi n}{N-1}\right)$

Hanning $w_{Hn}[n] = 0.5 \left[1 - \cos\left(\frac{2\pi n}{N-1}\right) \right]$


Bartlett $w_B[n] = 1 - \left| \frac{n - \frac{N-1}{2}}{\frac{N-1}{2}} \right|$

Krótkookresowa transformata Fouriera

Przykład porównujący użycie okna prostokątnego i okna Hamminga (szerokość okna wynosi **64**).




Fragment sekwencji po użyciu okna prostokątnego.




Fragment sekwencji po użyciu okna Hamminga.

Krótkookresowa transformata Fouriera

Przykład porównujący użycie okna prostokątnego i okna Hamminga.





STFT sekwencji po użyciu okna prostokątnego.




STFT sekwencji po użyciu okna Hamminga.

Krótkookresowa transformata Fouriera

Porównanie periodogramów przy użyciu okna prostokątnego i okna Hamminga.



Okno prostokątne



Okno Hamminga

Krótkookresowa transformata Fouriera

Przykład (analiza sygnałów akustycznych): Jak dobrać szerokość okna dla STFT stosowanej do analizy takich sygnałów?

Szerokość *okna* zależy od dwóch przeciwstawnych czynników:

1. Zakłada się, że w ramach całego okna charakterystyka częstotliwościowa sygnału powinna być (w przybliżeniu) stała, a więc **okno powinno być wystarczająco wąskie (krótkie)**.
2. Jeśli szerokość okna wynosi w , to częstotliwości niższe niż $1/w$ (w Hz) lub $2\pi/w$ (w radianach) są pomijane, bo okno jest za wąskie, żeby „zmieścić” chociaż jeden pełny okres takich częstotliwości. Tak więc **okno powinno być wystarczająco szerokie (długie)**.

Człowiek odbiera sygnały akustyczne o częstotliwościach wyższych niż $\sim 20\text{Hz}$. Tak więc minimalna szerokość okna powinna wynosić ok.

$$\frac{1}{20[\text{Hz}]} = 0.05[\text{sek}] = 50[\text{milisekund}]$$

Krótkookresowa transformata Fouriera

Dla sygnałów cyfrowych szerokość *okna* mierzona jest liczbą próbek. Przy ustalonej czasowej długości okna, liczba próbek w oknie zależy od **częstotliwości próbkowania**.

W sygnałach akustycznych (gdzie maksymalne częstotliwości nie przekraczają $\sim 20\text{kHz}$) częstotliwość próbkowania powinna wynosić co najmniej **40kHz** (czyli ok. **25 mikrosekund** na jedną próbkę).

Ponieważ $\tau=50$ *milisekund*, w oknie o takim czasie trwania będzie **$N = 2000$** próbek.

W praktycznych zastosowaniach, STFT sygnałów akustycznych jest najczęściej obliczana z użyciem okna o długości **$N = 2048$** próbek.

Uwaga: Jeśli sygnały akustyczne próbkowane są z mniejszą częstotliwością (np. w telefonii cyfrowej) liczba próbek w oknie będzie odpowiednio mniejsza. Np. przy częstotliwości próbkowania **10kHz**, w oknie o długości **50 milisekund** będziemy mieli **$N = 500$** próbek.

Transformacje falkowe (*wavelet transforms*)

Krótkookresowa transformacja Fouriera jest funkcją DWÓCH argumentów:

ω (częstotliwość) i N (położenie okna w analizowanej sekwencji) .

Pierwszy określa jakie częstotliwości występują w sygnale, a drugi pokazuje w której części sygnału te częstotliwości występują.

Transformacje falkowe idą w podobnym kierunku, ale zamiast sinusoid o zróżnicowanej częstotliwości sygnały „rozkłada się” w inny sposób i na zupełnie inne funkcje bazowe.

Transformacje falkowe (*wavelet transforms*)

W transformacjach falkowych sygnały „rozkładamy” na funkcje o określonym kształcie (spełniające pewne wymagania matematyczne) które mogą być *przeskalowane* (w pewnym sensie odpowiada to zmianie częstotliwości) oraz *przesunięte* (odpowiada to przesuwającej się funkcji okna).

Zakładając pewien „wzorcowy” kształt tych funkcji $\psi(t)$, funkcje bazowe mają ogólną postać:

$$\frac{1}{\sqrt{a}} \psi\left(\frac{t-b}{a}\right)$$


gdzie symbol b reprezentuje *przesunięcie* danej funkcji bazowej, a symbol a reprezentuje jej *skalę*.

Normalizacja amplitudy (pierwiastek z a) wymagana jest ze względów matematycznych.


Transformacje falkowe (*wavelet transforms*)

Gdy $b = 0$ i $a = 1$, mamy „wzorcową” funkcję bazową $\psi(t)$, którą nazywamy *falką podstawową* (lub *falką matką*, ang. *mother wavelet*).

Funkcje ψ muszą spełniać pewne warunki, ale zazwyczaj używamy kilku najbardziej popularnych kształtów falek podstawowych definiujących odpowiednie *transformacje falkowe*, np.:



Falka matka “sombbrero”



Falka matka Haara

Transformacje falkowe (*wavelet transforms*)

Definicja transformaty falkowej sygnału $x(t)$:

$$\mathcal{W}[x(t)] = X_\psi(a, b) = \frac{1}{\sqrt{a}} \int_{-\infty}^{+\infty} x(t) \psi\left(\frac{t-b}{a}\right) dt$$

$$\mathcal{W}_i(a_x, a_y, b_x, b_y) = \frac{1}{\sqrt{a_x a_y}} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} i(x, y) \psi\left(\frac{x-b_x}{a_x}, \frac{y-b_y}{a_y}\right) dx dy$$

Wariant dla sygnałów 2D

Definicja odwrotnej transformaty falkowej:

$$x(t) \sim \int_0^{+\infty} \int_{-\infty}^{+\infty} X_\psi(a, b) \frac{1}{\sqrt{a}} \psi\left(\frac{t-b}{a}\right) db \frac{da}{a^2}$$

UWAGA: Transformatę falkową należy uzupełnić tzw. *funkcją skalującą* (lub inaczej *funkcją córką*), która reprezentuje składową stałą sygnału.


Transformacje falkowe (*wavelet transforms*)

W typowych zastosowaniach stosuje się zdyskretyzowane warianty transformat falkowych, gdzie zakłada się, że sygnały są określone jedynie na przedziale $[0; 1]$, który dzielimy na $2, 4, 8, \dots, 2^m$ podprzedziałów (reprezentujących różne skale i możliwości przesuwania przeskalowanej falki podstawowej). Inaczej mówiąc, zamiast ciągłych parametrów a i b używamy tylko liczb całkowitych 2^m i k :

$$\frac{1}{\sqrt{a}}\psi\left(\frac{t-b}{a}\right) \Rightarrow \sqrt{2^m}\psi(2^m t - k)$$

Sygnały dyskretne określone są więc na przedziale $[0; 1]$ w ten sposób, że 2^M próbek reprezentowanych jest przez tyle samo podprzedziałów (przykład dla transformaty Haara danych o ośmiu próbkach na następnym slajdzie).

Transformacje falkowe (*wavelet transforms*)



Zauważmy, transformata ta ma tylko 7 (ogólnie $2^M - 1$) funkcji bazowych. Jako ostatnią (a raczej pierwszą) funkcję bazową dodatkowo przyjmujemy *funkcję córkę*, która w tym przypadku (i ogólnie najczęściej) ma wartość stałą równą 1.

Transformacje falkowe (*wavelet transforms*)

Funkcja córka pełni rolę zerowej częstotliwości (sygnał o stałej wartości).

Okazuje się, że po dodaniu *funkcji córki*, *transformatę Haara* sekwencji o $N = 2^M$ elementach obliczamy przez proste mnożenie macierzowe:

$$X_{\psi}(m, k) = \mathbf{H}_{2^M} \cdot \mathbf{x}$$

gdzie $\mathbf{H}_N$ nazywamy macierzami Haara (wyznaczanymi na podstawie przeskalowanych i przesuniętych „falek-matek”).

$$H_4 = \frac{1}{2} \begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & 1 & -1 & -1 \\ \sqrt{2} & -\sqrt{2} & 0 & 0 \\ 0 & 0 & \sqrt{2} & -\sqrt{2} \end{bmatrix}$$

$$H_8 = \frac{1}{2\sqrt{2}} \begin{bmatrix} 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & -1 & -1 & -1 & -1 \\ \sqrt{2} & \sqrt{2} & -\sqrt{2} & -\sqrt{2} & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & \sqrt{2} & \sqrt{2} & -\sqrt{2} & -\sqrt{2} \\ 2 & -2 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 2 & -2 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 2 & -2 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 2 & -2 \end{bmatrix}$$

Transformacje falkowe (*wavelet transforms*)

Przykład obliczania transformaty Haara:

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \\ 5 \\ 6 \\ 7 \\ 8 \end{bmatrix}$$

$$X_\psi(m, k) = \mathbf{H}_8 \cdot \mathbf{x} = \begin{bmatrix} 12.7279 \\ -5.6569 \\ -2 \\ -2 \\ -0.7071 \\ -0.7071 \\ -0.7071 \\ -0.7071 \end{bmatrix}$$

$$H_8 = \frac{1}{2\sqrt{2}} \begin{bmatrix} 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & -1 & -1 & -1 & -1 \\ \sqrt{2} & \sqrt{2} & -\sqrt{2} & -\sqrt{2} & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & \sqrt{2} & \sqrt{2} & -\sqrt{2} & -\sqrt{2} \\ 2 & -2 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 2 & -2 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 2 & -2 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 2 & -2 \end{bmatrix}$$


Odwrotną transformatę obliczamy analogicznie:

$$\mathbf{H}_8^{-1} X_\psi(m, k) = \mathbf{H}_8^T X_\psi(m, k) = \mathbf{x}$$

Transformacje falkowe (*wavelet transforms*)

Ponieważ transformata falkowa jest funkcją dwóch argumentów, to uzyskany wektor jest tak naprawdę strukturą dwuwymiarową:

$$X_{\psi}(m,k) = \begin{bmatrix} 12.7279 \\ -5.6569 \\ -2 \\ -2 \\ -0.7071 \\ -0.7071 \\ -0.7071 \\ -0.7071 \end{bmatrix} \Leftrightarrow \begin{bmatrix} 12.7279 \text{ (funkcja córka)} \\ -5.6569 \text{ (falka matka)} \\ -2 & -2 \\ -0.7071 & -0.7071 & -0.7071 & -0.7071 \end{bmatrix}$$



Transformacje falkowe (*wavelet transforms*)

Przykład ilustrujący wykorzystanie transformacji falkowych dla danych 2D (obrazów).

